

שקילות רגרסיה לוגיסטית

גיא עשירי-פרוסנר

האוניברסיטה העברית, מרכז ארצי לבחינות ולהערכה

11.02.2020

רקע: שקילות מודלים

- ◀ קבוצות אוכלוסיה נבדלות זו מזו בפרמטרים שונים:
מין, גזע, גיל, תרבות, מצב סוציו-אקונומי...
- ◀ לכל אוכלוסיה ניתן להתאים מודל
- ◀ שקילות מודלים היא נושא חשוב מבחינה פסיכומטרית
- ◀ חשיבות מדעית (רוצים לדעת שהתופעה זהה בשתי קבוצות)
- ◀ בהנתן מודל קיים ואוכלוסיה חדשה, ייתכן שנרצה לשמור על המודל:
 - הוא מספק לנו הסבר טוב של התופעה
 - הוא מתאים לתאוריה
 - מומחים צברו מיומנות בשימוש בו
 - מחקרי המשך מתבססים עליו

רקע: שקילות מודלים

◀ החלפת מודל או ביצוע שינויים במודל הקיים עלולים לגרום:

- אובדן כח מסבירני
- התאמה פחות טובה לנתונים הישנים
- פגיעה במהימנות המודל הישן והמחקרים הנסמכים עליו

◀ עבור השוואת מודלים של ניתוח גורמים, קיימת מערכת הכלים Measurement Invariance

◀ דוגמאות:

- שקילות מודל 4 גורמי האישיות על בסיס מין (Byrne, 1988)
- שקילות מודל 5 גורמי ההעדפות התעסוקתיות על בסיס גזע (Collins & Gleaves, 1998)
- אי שקילות מודל גורמי של שאלון ערכי המשפחה (Byrne & van de Vijver, 2010)

רקע: רגרסיה לוגיסטית

מודל סטטיסטי המשמש לחיזוי ערכו של משתנה בינארי y_i על בסיס ערכיהם של משתנים רציפים x_{1i}, \dots, x_{pi} , לדוגמא:

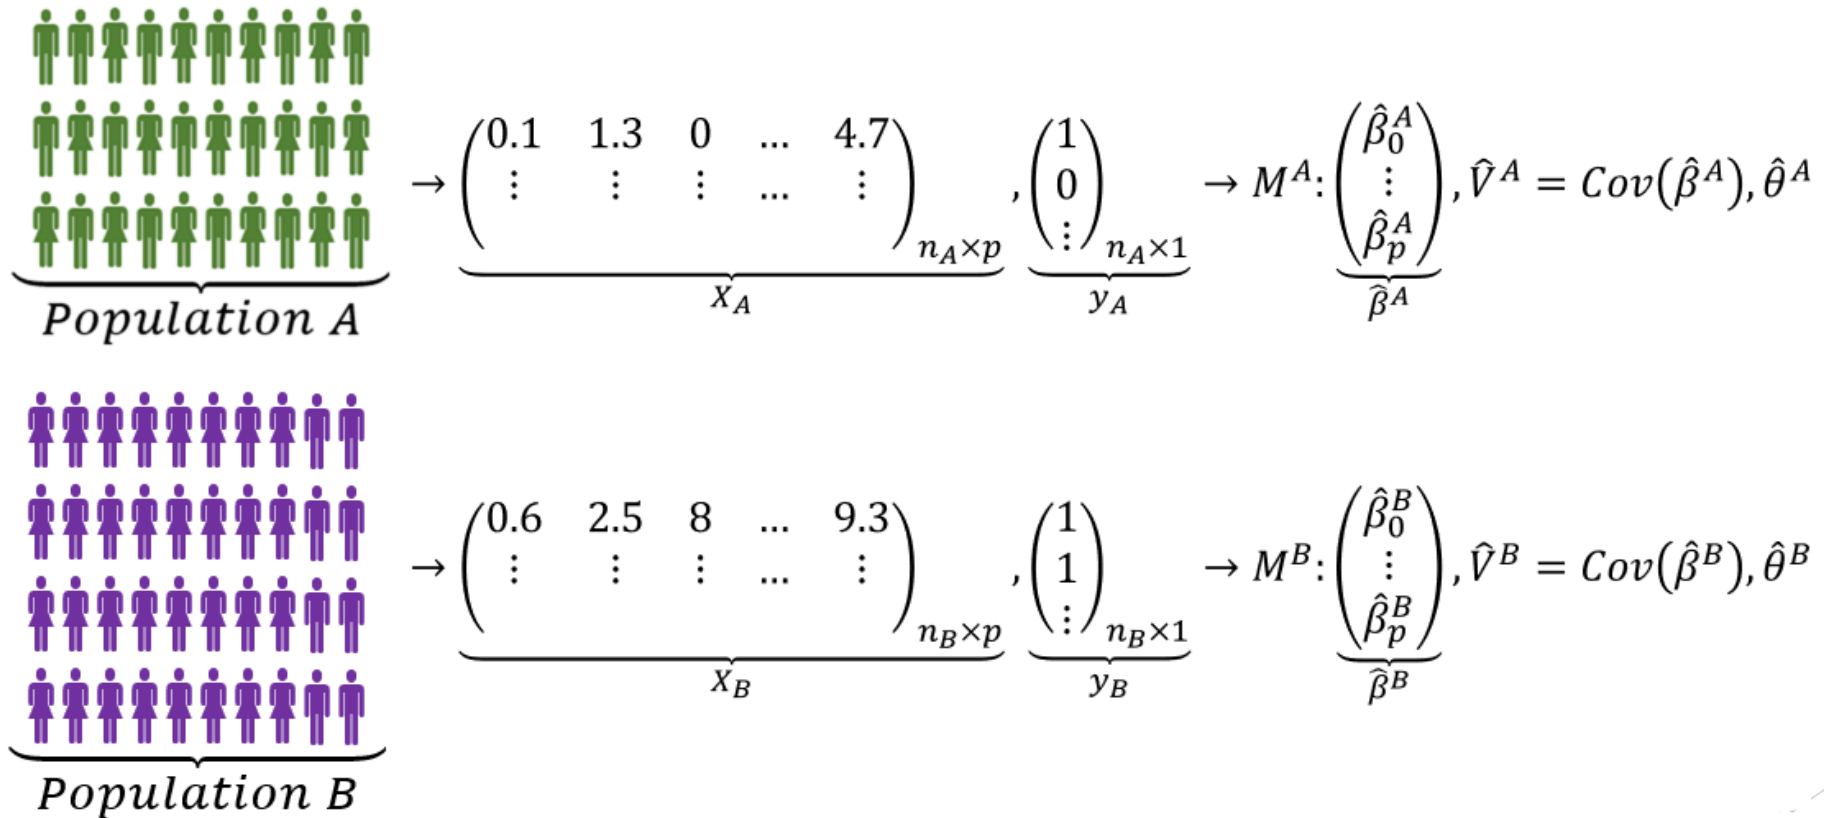
	x1	x2	x3	x4	x5	y_dyslexia
1	-2.05	-4.02	-3.52	-1.30	-0.89	0
2	-2.24	-2.79	-1.30	-0.63	-0.22	1
3	-1.75	-1.01	-3.35	-1.48	-0.79	0
4	-1.32	-2.54	-1.20	-1.50	-0.97	0
5	-0.73	0.24	-0.77	-1.60	-1.25	1
6	-3.08	-3.17	-3.56	-1.55	-3.01	1

לכל תצפית i מחושבים המנבא $\theta_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi}$ והסתברות להימצאות לקות באופן

$$P(y_i = 1|x_i) = \pi_i = \frac{e^{\theta_i}}{1 + e^{\theta_i}}$$

התחזית לכל תצפית נקבעת לפי נקודת חתך c , באופן $\hat{y}_i = \begin{cases} 1 & \hat{\pi}_i \geq c \\ 0 & \hat{\pi}_i < c \end{cases}$

רקע: רגרסיה לוגיסטית



Population A

$$\rightarrow \underbrace{\begin{pmatrix} 0.1 & 1.3 & 0 & \dots & 4.7 \\ \vdots & \vdots & \vdots & \dots & \vdots \end{pmatrix}}_{X_A}^{n_A \times p}, \underbrace{\begin{pmatrix} 1 \\ 0 \\ \vdots \end{pmatrix}}_{y_A}^{n_A \times 1} \rightarrow M^A: \underbrace{\begin{pmatrix} \hat{\beta}_0^A \\ \vdots \\ \hat{\beta}_p^A \end{pmatrix}}_{\hat{\beta}^A}, \hat{V}^A = \text{Cov}(\hat{\beta}^A), \hat{\theta}^A$$

Population B

$$\rightarrow \underbrace{\begin{pmatrix} 0.6 & 2.5 & 8 & \dots & 9.3 \\ \vdots & \vdots & \vdots & \dots & \vdots \end{pmatrix}}_{X_B}^{n_B \times p}, \underbrace{\begin{pmatrix} 1 \\ 1 \\ \vdots \end{pmatrix}}_{y_B}^{n_B \times 1} \rightarrow M^B: \underbrace{\begin{pmatrix} \hat{\beta}_0^B \\ \vdots \\ \hat{\beta}_p^B \end{pmatrix}}_{\hat{\beta}^B}, \hat{V}^B = \text{Cov}(\hat{\beta}^B), \hat{\theta}^B$$

רקע: השוואת מודלים של רגרסיה לוגיסטית

שלוש שאלות אפשריות בהשוואת מודלים של רגרסיה לוגיסטית:

1. כיצד המודל מתאר את התופעה?

- נשתמש בוקטור מקדמי הרגרסיה $\hat{\beta}$
- הוקטור מספק הצצה לאופן בו המודל מסביר את התופעה

2. באיזו מידה הפלט של המודל מתאים לתצפיות?

- לכל תצפית x_i המודל מתאים את המנבא $\hat{\theta}_i$, ההסתברות $\hat{\pi}_i$ והתחזית \hat{y}_i
- נבחר להשתמש ב- $\hat{\theta}_i$ כיוון שהוא על הישר הממשי

3. במצטבר, עד כמה מדויק המודל?

- נשתמש בציון ברייר (Brier Score)

רקע: מבחני שקילות

◀ מרבית הכלים להשוואה בין מודלים מתבססים על מבחני מובהקות:

- השערת האפס היא שלא קיים אפקט בין המודלים ($H_0: |\mu^A - \mu^B| = 0$)
- האזור בו לא דוחים את השערת האפס מתכווץ ככל שהמדגם גדל
- מצב זה מתמרץ שימוש במדגמים קטנים כדי להראות שאין הבדל

◀ הפתרון: שימוש במבחני שקילות

- מגדירים רמת רגישות - גודל אפקט מינימלי להתייחסות ($H_0: |\mu^A - \mu^B| < \delta$)
- הופכים את ההשערות - השערת האפס היא שקיים אפקט בגודל δ לפחות:
$$H_0: |\mu^A - \mu^B| \geq \delta, \quad H_1: |\mu^A - \mu^B| < \delta$$
- האזור בו דוחים את השערת האפס מתרחב ככל שהמדגם גדל
- מצב זה מתמרץ שימוש במדגמים גדולים כדי להראות שאין הבדל

מטרת המחקר

◀ פיתוח שיטות להשוואת מודלים של רגרסיה לוגיסטית בין אוכלוסיות, בהסתמך על מאפיינים שונים של המודלים ועל ידי שימוש במבחני שקילות

שיטה: השוואת וקטור מקדמי הרגרסיה

◀ נניח כי קיימים לנו מודלים M^A, M^B עם וקטורי המקדמים $\hat{\beta}^A, \hat{\beta}^B$

◀ נגדיר את וקטור ההפרשים $\hat{q} = \hat{\beta}^A - \hat{\beta}^B$, מטריצת השוננויות
 $Cov(\hat{q}) = S_q$

◀ נגדיר רמת רגישות בין מקדמים תואמים δ_β ($|\hat{\beta}_j^A - \hat{\beta}_j^B| \leq \delta_\beta$)

◀ עבור מודל עם p משתנים מנבאים, נבנה וקטור באורך p : δ_β^p

◀ מרחק Mahalanobis המותר בין הוקטורים: $\lambda_\beta^2 = \delta_\beta^{pT} S_q^{-1} \delta_\beta^p$

◀ השערות:

$$H_0: \|\beta^A - \beta^B\|_\Sigma \geq \lambda_\beta, \quad H_1: \|\beta^A - \beta^B\|_\Sigma < \lambda_\beta$$

◀ מבחן ברמה α לשקילות וקטורי המקדמים:

$$\left\{ \hat{q}^T S_q^{-1} \hat{q} < \chi_{p,\alpha}^2 \left(\delta_\beta^{pT} S_q^{-1} \delta_\beta^p \right) \right\}$$

שיטה: השוואת וקטור המנבאים

- ◀ נניח אוסף נתונים X_C בגודל k . עבור תצפית מסוימת $x_i \in X_C$, מודל M^A מפיק את המנבא $\hat{\theta}_i^A$ ואילו מודל M^B מפיק את המנבא $\hat{\theta}_i^B$
- ◀ יחס סיכויים: השינוי בהסתברות לקבל $\hat{y}_i = 1$ כאשר מחליפים מודל
- ◀ לוג יחס הסיכויים הוא $\hat{\xi}_i = \hat{\theta}_i^A - \hat{\theta}_i^B$. אנו מעוניינים בגודל השינוי ולא בכיוון: $\tilde{\xi}_i = |\hat{\theta}_i^A - \hat{\theta}_i^B|$
- ◀ נגדיר רמת רגישות לשינוי פר תצפית δ_θ
- ◀ השערות:

$$H_0: \mu_{\tilde{\xi}} \geq \delta_\theta, \quad H_1: \mu_{\tilde{\xi}} < \delta_\theta$$

- ◀ מבחן ברמה α לשקילות וקטורי המנבאים:

$$\left\{ \frac{\sqrt{k}(\bar{\tilde{\xi}} - \delta_\theta)}{\sqrt{\widehat{Var}(\tilde{\xi})}} < t_{1-\frac{\alpha}{2}, k-1} \right\}$$

שיטה: השוואת ציוני ברייר

- עבור תצפית מסוימת $x_i \in X_C$, מודל M^A מפיק את ההסתברות $\hat{\pi}_i^A$ ואילו מודל M^B מפיק את ההסתברות $\hat{\pi}_i^B$
- ציון ברייר (Brier Score) לביצועים של מודל M^A על אוכלוסיה X_C :

$$BS_{AC} = \frac{1}{k} \sum_{i=1}^k (\hat{\pi}_i^A - y_i)^2$$

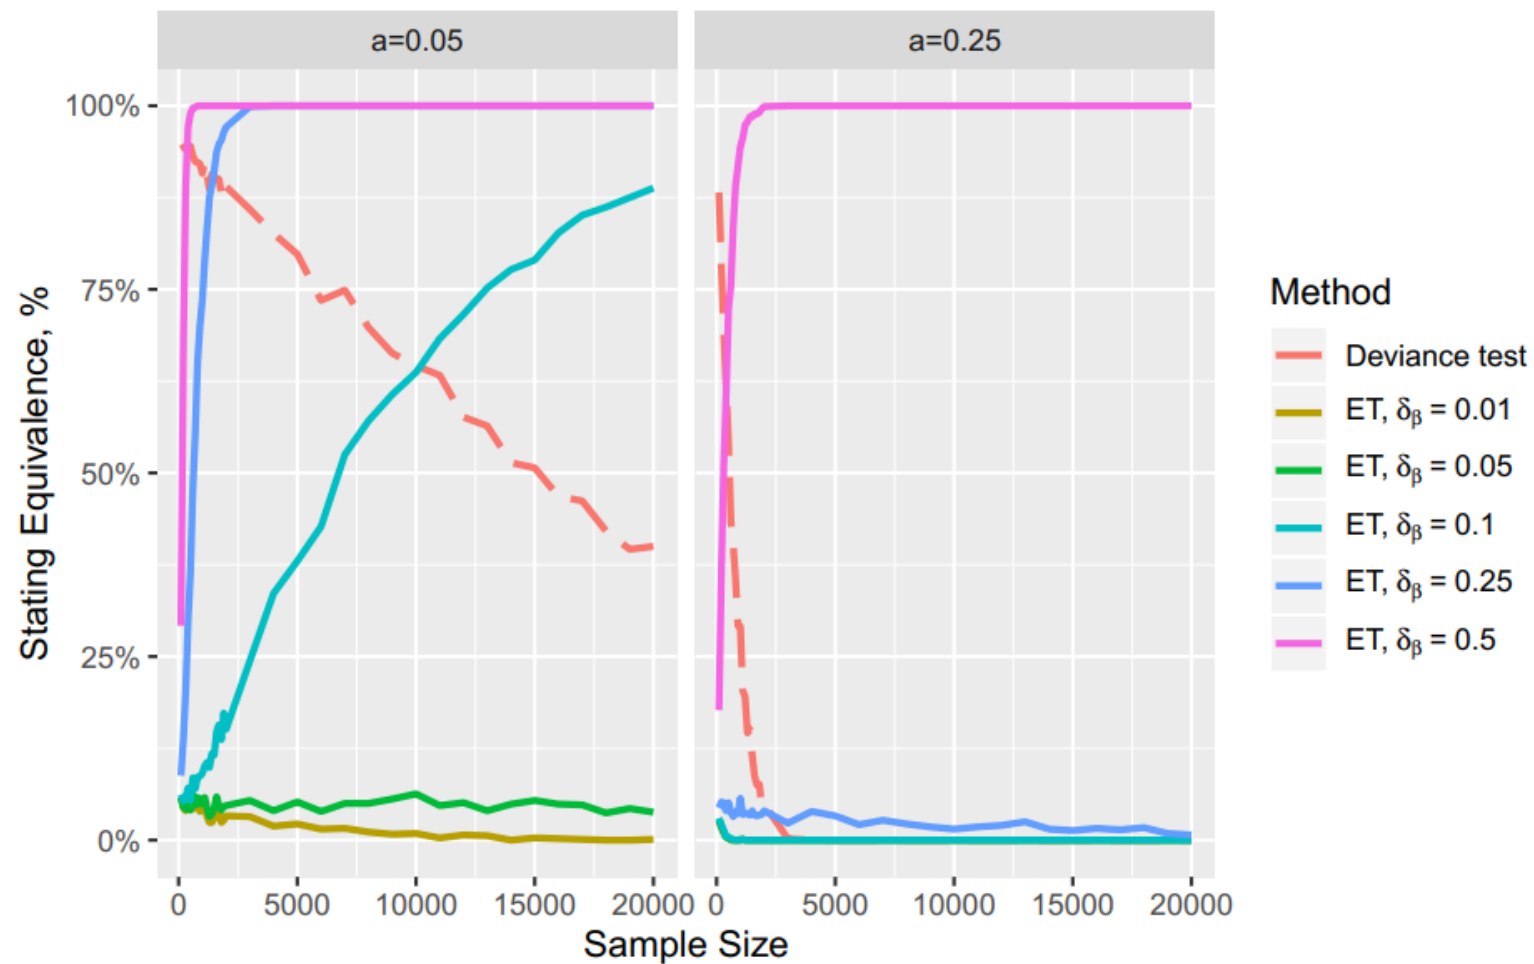
- ההפרש בין ביצועי המודלים: $D_{AB} = BS_{AC} - BS_{BC}$
- נגדיר רמת רגישות לשינוי בציון ברייר δ_B
- מבחן ברמה α לשקילות ציוני ברייר:

$$\left\{ \frac{\sqrt{k}(D_{AB} + \delta_B)}{\sqrt{s_D^2}} > t_{1-\alpha, k-1} \quad \bigwedge \quad \frac{\sqrt{k}(D_{AB} - \delta_B)}{\sqrt{s_D^2}} < -t_{1-\alpha, k-1} \right\}$$


תוצאות: הגדרת הסימולציה

- ◀ בונים מדגמים x^A, x^B בגודל n מהתפלגות נורמלית סטנדרטית
- ◀ מגדירים אפקט בגודל a בין המדגמים: $\beta^A = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \beta^B = \begin{pmatrix} a \\ 1 - a \end{pmatrix}$
- ◀ מגרילים את וקטורי y^A, y^B לפי המודל הלוגיסטי עם $\theta_i = x_i^T \beta$
- ◀ בונים מודלים M^A, M^B
- ◀ שימוש בגדלי מדגמים $n = 100, \dots, 2000, 3000, \dots, 20000$
- ◀ גדלי אפקטים $a = 0.05, 0.25$
- ◀ לכל שילוב של גודל מדגם וגודל אפקט עורכים 1000 חזרות
- ◀ בכל חזרה משתמשים בשיטת השקילות ובשיטת השוואה קיימת


תוצאות: השוואת וקטור מקדמי הרגרסיה



תוצאות: השוואת וקטור המנבאים



תוצאות: השוואת ציוני ברייר



תוצאות: שימוש בנתוני מת"ל

- ◀ מת"ל היא מערכת לאבחון תפקודי למידה
- ◀ על בסיס 22 מטלות ושאלונים מופקות 4 אבחנות
- ◀ האבחנות הממוחשבות מופקות באמצעות רגרסיה לוגיסטית
- ◀ מדגם מחקרי: $n = 1046$, בחלוקה לפי מין: $n_m = 455, n_f = 591$
- ◀ לכל תת-קבוצה נבנו מודלים לניבוי דיסגרפיה ודיסקלקוליה

תוצאות: שימוש בנתוני מת"ל

◀ דיסגרפיה

- שיטת שקילות מקדמים: המודלים **שקולים** בין המינים
- שיטת שקילות מנבאים: המודלים **אינם שקולים** בין המינים
- שיטת שקילות ציוני ברייר: המודלים **שקולים** בין המינים
- מחקר fMRI (Berninger & O'Malley May, 2011): מרבית תפקודי הכתיבה שקולים בין המינים

◀ דיסקלקוליה

- שיטת שקילות מקדמים: המודלים **אינם שקולים** בין המינים
- שיטת שקילות מנבאים: המודלים **אינם שקולים** בין המינים
- שיטת שקילות ציוני ברייר: המודלים **שקולים** בין המינים
- מחקר (Devine et al, 2013): דיסקלקוליה התפתחותית שונה בין המינים

דיון

- ◀ כל שיטה מספקת תובנה שונה לגבי שקילות אפשרית בין המודלים
- ◀ שילוב השיטות מספק השוואה מקיפה
- ◀ שיטות פשוטות ליישום ושימוש
- ◀ ייתכן כי שיטת שקילות log-odds שמרנית מדי
- ◀ ייתכן כי שיטת שקילות ציוני ברייר מתירנית מדי, לעתים סותרת את השיטות האחרות
- ◀ בחירת רמת רגישות δ דורשת מיומנות רבה, זהו "קושי מתודולוגי עיקרי" של מבחני שקילות (Greene et al., 2008)

תודה על ההקשבה

שאלות?

guy@nite.org.il